

Simulations pour le screening sortie Poisson avec variables supplémentaires V12_parallélisation - Version commentée

J. Dedecker, M.-L. Taupin et A.-S. Tocquet

2026-04-01

Contents

1	Etapes des calculs:	2
1.1	Simulation du design	2
1.2	Calcul du prédicteur linéaire	3
1.3	Génération des Y_i	3
1.4	2) Calcul des $\hat{\tau}^{(j)}$	3
1.5	3) Calcul des $\hat{\tau}^{(j)}$ pour les variables non liées aux Y_i	3
1.6	4) Calcul des intercept ($\hat{\tau}_0^{(j)}$) individuels pour les régression linéaires simples (variables par variables) en utilisant la formule:	3
1.7	5) Calcul des résidus $\hat{\varepsilon}_i^{(j)}$	3
1.8	6) Calcul de la variance de White en utilisant la formule:	4
1.9	7) On calcule ensuite les $\hat{\tau}^{(j)}$ renormalisés avec la formule:	4
1.10	8) On sait que pour les $j > 10$	4
1.11	9) Etape de Monte Carlo pour calculer les faux positifs et les faux négatifs sur N échantillons.	4
2	Code R	4
2.1	Packages	4
2.2	1) Fonction qui simule de la matrice de design avec des gaussiennes dépendantes	5
2.3	2) Calcul des vraies valeurs des paramètres (attention aux notations / article)	5
2.4	3) Différents paramètres comme $n, N, d, D, \dots$	6
2.5	4) fonction qui calcule les $\hat{\gamma}^{(j)}$	6
3	Parallélisation	7
4	mise en forme des resultats	7

1 Etapes des calculs:

1.1 Simulation du design

On a 4 groupes de variables:

- Le groupe $\mathcal{A}$ qui contient les variables X_1 à X_7 à X_{10} et qui génèrent les Y_i
- Le groupe $\mathcal{B}$ qui contient des variables X_{11} à X_{14} qui sont des variables bruitées de X_1 , X_3 , X_4 et X_5 . Elles sont corrélées à X_1 , X_3 , X_4 et X_5 (qui génèrent les Y_i), mais elles ne génèrent pas les Y_i .
- Le groupe $\mathcal{C}$ qui contient des variables corrélées à X_{11} , X_{12} , X_{13} et X_{14} mais qui sont indépendantes des Y_i . Ces variables X_{15} , X_{16} , X_{17} et X_{18} ne doivent pas sortir: ce seront des faux positifs.
- Le groupe $\mathcal{D}$ contient les 1 – 18 variables indépendantes de toutes les autres variables du design et qui ne génèrent pas les Y_i

Plus précisément, le design est tel que:

- X_0 est l'intercept.
- X_1, X_2, X_3, X_4, X_5 sont des gaussiennes dépendantes qui interviennent toutes dans la génération des Y_i , comme l'intercept. Leur matrice de covariance est la matrice de Toeplitz suivante (avec $\rho = 0.57$ et $\sigma = 1$)

$$\Sigma = \begin{pmatrix} 1 & \rho & \rho^2 & \rho^3 & \rho^4 \\ \rho & 1 & \rho & \rho^2 & \rho^3 \\ \rho^2 & \rho & 1 & \rho & \rho^2 \\ \rho^3 & \rho^2 & \rho & 1 & \rho \\ \rho^4 & \rho^3 & \rho^2 & \rho & 1 \end{pmatrix}$$

Ensuite:

- $X_6 \sim \mathcal{B}(0.35)$ indépendantes des autres variables du design. La variable X_6 intervient dans la génération des Y_i
- $X_7 \sim \chi^2(2)$. La variable X_7 intervient dans la génération des Y_i .
- $X_8 = X_1 * \mathcal{P}(2)$. La variable X_8 intervient dans la génération des Y_i , mais la loi de Poisson n'intervient pas seule dans la génération des Y_i .
- $X_9 = X_2 * \mathcal{N}(1, 1)$ les deux étant indépendantes. La variable X_9 intervient dans la génération des Y_i , mais pas la $\mathcal{N}(1, 1)$ seule.
- $X_{10} = \mathcal{S}\sqcup(14)$. La variable X_{10} intervient dans la génération des Y_i .

1.1.0.1 Les autres variables:

- $X_{11} = X_1 + \mathcal{N}(0, 04^2) = X_1 + Z_3$.
- $X_{12} = X_3 + \mathcal{N}(0, 02^2) = X_3 + Z_4$.
- $X_{13} = X_4 + \mathcal{N}(0, 0.35^2) = X_4 + Z_5$.
- $X_{14} = X_5 + \mathcal{N}(0, 055^2) = X_5 + Z_6$.

- $X_{15} = Z_3$
- $X_{16} = Z_4$
- $X_{17} = Z_5$
- $X_{18} = Z_6$

The variables $X^{(19)}, X^{(20)}, \dots, X^{(1000)}$ are independent of $(Y, X^{(1)}, \dots, X^{(18)})$. These variables form a stationary Gaussian sequence with mean 0 and variance 1, and covariance matrix similar to the matrix Σ above (but now it is a 1986×1986 square matrix), with $\rho = 0.7$.

1.2 Calcul du prédicteur linéaire

$$X\theta^* = \theta_0^* + \theta_1^*X^{(1)} + \dots + \theta_{10}^*X^{(10)}.$$

1.3 Génération des Y_i

1.3.0.1 The output follows a Poisson distribution: The output Y is generated as follows:

$$Y \sim \mathcal{P} \left(\left| \theta_0^* + \theta_1^*X^{(1)} + \dots + \theta_{10}^*X^{(10)} \right| \right),$$

where θ^* is such that

$$\theta^* = (-1, 3.619350, -3.274923, 2.963273, -2.681280, 2, 4, 6, 3, 2, 4)^T.$$

Remarque: $\theta^* = \alpha$ où α_j sont les valeurs dans l'article.

1.4 2) Calcul des $\hat{\tau}^{(j)}$

On rappelle que pour $j = 1, \dots, p$,

$$\hat{\tau}^{(j)} = \frac{\text{Cov}_n(\mathbf{X}^{(j)}, \mathbf{Y})}{\text{Var}_n(\mathbf{X}^{(j)})}.$$

1.5 3) Calcul des $\hat{\tau}^{(j)}$ pour les variables non liées aux Y_i

1.6 4) Calcul des intercept ($\hat{\tau}_0^{(j)}$) individuels pour les régression linéaires simples (variables par variables) en utilisant la formule:

$$\hat{b}^{(j)} = \bar{Y} - \hat{\tau}^{(j)}\bar{X}^{(j)}.$$

1.7 5) Calcul des résidus $\hat{\varepsilon}_i^{(j)}$

Puis on définit les résidus liés aux régressions linéaires simples (variable par variable) en utilisant que pour $j = 1, \dots, 1000$,

$$\hat{\varepsilon}_i^{(j)} = Y_i - \hat{b}^{(j)} - \hat{\tau}^{(j)}X_i^{(j)}.$$

1.8 6) Calcul de la variance de White en utilisant la formule:

$$\hat{V}^{(j)} = \frac{n^{-1} \sum_{i=1}^n \left[(X_i^{(j)} - \bar{\mathbf{X}}^{(j)})^2 (\hat{\varepsilon}_i^{(j)})^2 \right]}{\text{Var}_n^2(\mathbf{X}^{(j)})}.$$

1.9 7) On calcule ensuite les $\hat{\tau}^{(j)}$ renormalisés avec la formule:

$$\hat{\gamma}^{(j)} = \frac{\sqrt{n} \hat{\tau}^{(j)}}{\sqrt{\hat{V}^{(j)}}},$$

où

$$\hat{V}^{(j)} = \frac{n^{-1} \sum_{i=1}^n \left[(X_i^{(j)} - \bar{\mathbf{X}}^{(j)})^2 (\hat{\varepsilon}_i^{(j)})^2 \right]}{\text{Var}_n^2(\mathbf{X}^{(j)})}.$$

1.10 8) On sait que pour les $j > 10$

$$\hat{\gamma}^{(j)} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

A noter que pour $j = 1, \dots, 10$ il faut recentrer et écrire:

$$\left(\hat{\gamma}^{(j)} - \gamma^{(j)} \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1),$$

où

$$\left(\hat{\gamma}^{(j)} - \gamma^{(j)} \right) = \frac{\sqrt{n} \left(\hat{\tau}^{(j)} - \tau^{(j)} \right)}{\sqrt{\hat{V}^{(j)}}},$$

avec

$$\tau^{(j)} = \frac{\text{Cov}(Y, X^{(j)})}{\text{Var}(X^{(j)})}, \quad \text{et} \quad V^{(j)} = \frac{\mathbb{E} \left[\left(X^{(j)} - \mathbb{E}(X^{(j)}) \right)^2 \varepsilon^{(j)2} \right]}{\left(\text{Var}(X^{(j)}) \right)^2}.$$

1.11 9) Etape de Monte Carlo pour calculer les faux positifs et les faux négatifs sur N échantillons.

2 Code R

2.1 Packages

```
knitr::opts_chunk$set(echo = TRUE, eval = TRUE)
library(parallel, quietly = TRUE)
detectCores()
```

```
## [1] 14
```

```
library(lme4, quietly=TRUE)
```

```
## Warning: package 'lme4' was built under R version 4.4.3
```

```
## Warning: package 'Matrix' was built under R version 4.4.3
```

```
library(kableExtra,quietly=TRUE)
library(knitr,quietly = TRUE)
```

```
## Warning: package 'knitr' was built under R version 4.4.3
```

```
library(devtools,quietly=TRUE)
```

```
## Warning: package 'devtools' was built under R version 4.4.3
```

```
library(Rcpp,quietly=TRUE)
```

```
## Warning: package 'Rcpp' was built under R version 4.4.3
```

```
library(matrixStats,quietly = TRUE)
library(collapse,quietly = TRUE)
```

```
## Warning: package 'collapse' was built under R version 4.4.3
```

```
## collapse 2.1.6, see ?'collapse-package' or ?'collapse-documentation'
```

```
##
```

```
## Attaching package: 'collapse'
```

```
## The following object is masked from 'package:stats':
```

```
##
```

```
##      D
```

2.2 1) Fonction qui simule de la matrice de design avec des gaussiennes dépendantes

```
simu_design = function(n = n, d=d, mu=mu, rho=rho,sigma = sigma){
  create_cor = function(i){return(rho**(i-1)*sigma^2)}
  vec = sapply(c(1:d), FUN = create_cor)
  Sigma = lqmm::make.positive.definite(toeplitz(vec))
  design = mvtnorm::rmvnorm(n, mean = mu , sigma = Sigma)
  colnames(design) = 1:d
  means_design = apply(design,2,mean)
  sds_design = apply(design,2,sd)
  return(list(design = as.data.frame(design), means_design = means_design, sds_design = sds_design, Sig
})
```

Cette fonction sert à simuler les 5 premières gaussiennes (qui génèrent les Y_i) ainsi que les 982 autres variables qui ne génèrent pas les Y_i et sont indépendantes des 18 premières variables.

2.3 2) Calcul des vraies valeurs des paramètres (attention aux notations / article)

```
J=c(1,2,3,4)
#theta1_5=2*((-1)^(J-1))*exp(-J/10)
#thetastar=2*c(-0.5,theta1_5,seq(1:3),1.5,1,2)
thetastar=rep(1:11)
D=length(thetastar)-1
```

2.4 3) Différents paramètres comme $n, N, d, D, \dots$

```
n = 500 #taille de l'échantillon
N=500 #nombre de répétitions pour Monte-Carlo
Dtotal=2000 #nombre total de variables
Dtilde=Dtotal-D-8 #Dtilde=1982
D #D=10 nombre de variables qui interviennent dans la génération des  $Y_i$ 
```

```
## [1] 10
```

```
Dtilde # attention !!!!
```

```
## [1] 1982
```

```
q_n=0.10 # taux de faux positifs qu'on se fixe
d=5 # le nombre de gaussiennes dépendantes du début
mu = rep(0,d) #espérance pour les 5 premières gaussiennes
sd=1 #écart type pour les 5 premières gaussiennes
rho= 0 #gère le niveau de dépendance pour les 5 premières colonnes de X
#Dtilde=nombre de variables non liées à la sortie Y
mu_tilde = rep(0,Dtilde) #espérances pour les 982 gaussiennes corrélées entre elles
rho_tilde=0.7 #gère le niveau de dépendance pour les 982 colonnes du design non liées à Y
s_Dtilde= 1 #écart type pour les 982 dernières gaussiennes
seuil_q_n=qnorm(1-q_n/2,0,1) # quantile de la gaussienne
```

2.5 4) fonction qui calcule les $\hat{\gamma}^{(j)}$

```
gamma_chapo=array(0,dim=c(N,Dtotal)) #utilité?
gamma_chapo_function = function(n = n, d=d, mu=mu, rho=rho,sigma = sd, Dtotal=Dtotal,mu_tilde=mu_tilde)
{
#design_df=simu_design(n=n,d=d,mu=mu,rho=rho,sigma=sd) # Simulation des 5 premières gaussiennes corrélées
design_mat=as.matrix(simu_design(n=n,d=d,mu=mu,rho=rho,sigma=sd)$design) # le début de ma matrice de de
Z3=rnorm(n,0.4)
Z4=rnorm(n,0.02)
Z5=rnorm(n,0,0.35)
Z6=rnorm(n,0,0.55)
X=cbind(design_mat,rbinom(n,size=1,p=0.35),rchisq(n,df=2),design_mat[,1]*rpois(n,2),design_mat[,2]*rnorm(n,0,0.35))
X=as.matrix(X) # matrice de design avec n lignes et 10 colonnes
colnames(X)=c("X1", "X2", "X3", "X4", "X5", "X6_bern", "X7_chisq2", "X8=X1*P(2)", "X9=N(1,1)*X2", "X10=Student (t(2))")
# Génération des  $Y_i$ 
predicteur_lineaire=thetastar[1]+X%*%thetastar[-1]
```

```

epsilon=rchisq(n,df=3)-3
Y=predicteur_lineaire+epsilon
Y=as.matrix(Y)
#####
Xtilde=matrix(0,nrow=n,ncol=Dtilde) #Utile?
#Dtilde=1982
#design_df_tilde=simu_design(n=n,d=Dtilde,mu=mu_tilde,rho=rho_tilde,sigma=s_Dtilde)
#Xtilde=as.matrix(design_df_tilde$design) # contient les 982 gaussiennes indépendantes de toutes les au
Xtilde=cbind(design_mat[,1]+Z3, design_mat[,3]+Z4, design_mat[,4]+Z5,design_mat[,5]+Z6, Z3,Z4,Z5,Z6, as
# maintenant X_tilde doit être de dimension Dtilde+8=1982+8=1990
Xcomplet=cbind(X,Xtilde)
Xcomplet=as.matrix(Xcomplet) #matrice de design complète
# Calcul des tau_chapo
tau_chapo=(t(t(Xcomplet)%*(scale(Y,center=TRUE,scale=FALSE))))/(t(colVars(Xcomplet))*(n-1))
# Calcul des  $\widehat{b}_j$ .
# est-ce qu'il remplir la matrice tau_chapo_0 de 0 avant de la remplir correctement?
b_chapo=mean(Y)-tau_chapo*(matrix(colMeans(Xcomplet),c(1,Dtotal)))
#calcul des  $\widehat{\text{varepsilon}}_i^{(j)}$ 
Matrice_residus_chapo= -(Xcomplet %r% t(tau_chapo)) %r-% t(b_chapo)) %c+% as.vector(Y)
#Calcul de la variance de White (sans passer par le remplissage de matrices intermédiaires)
V= t(as.matrix(colSums((scale(Xcomplet,center=TRUE,scale=FALSE))^2 * (Matrice_residus_chapo)^2) / n))/(
#calcul des gamma_chapo
gamma_chapo=sqrt(n)*(tau_chapo)/sqrt(V)
return(gamma_chapo) #on récupère les gamma_chapo
}

```

3 Parallélisation

```

g<- function (i){gamma_chapo_function(n = n, d=d, mu=mu, rho=rho,sigma = sigma, Dtotal=Dtotal,mu_tilde=
resultats <- mclapply(1:N, g, mc.cores = 12)

```

4 mise en forme des resultats

```

gamma_chapo= do.call(rbind, resultats)
save(gamma_chapo, file = "Continue_gamma_chapo_par_N500_n2500_qn010.RData")

```

```

gamma_chapo=as.matrix(gamma_chapo)
screen_18_par=colMeans(abs(gamma_chapo[,1:18]))>seuil_q_n)
screen_18_par=as.matrix(screen_18_par)
rownames(screen_18_par)=c("X1", "X2", "X3", "X4", "X5", "X6_bern", "X7_chisq2", "X8=X1*P(2)", "X9=N(1,1)*X2", "X
dim(screen_18_par)

```

```
## [1] 18 1
```

```
vrais_positifs=mean(screen_18_par[1:14],)
```

Table 1: N=500, n=2500, $q_n = 0.10$, Continuous Output

X1	1.000
X2	1.000
X3	0.842
X4	0.932
X5	0.982
X6_bern	0.648
X7_chisq2	1.000
X8=X1*P(2)	1.000
X9=N(1,1)*X2	1.000
X10=Student(14)	1.000
X11=X1+Z3	1.000
X12=X3+Z4	0.552
X13=X4+Z5	0.894
X14=X5+Z6	0.952
X15=Z3	0.104
X16=Z4	0.126
X17=Z5	0.094
X18=Z6	0.110
taux_vrais_positifs	0.914
taux_faux_positifs	0.104
cardinal_moyen_ensemble_indices_sélectionnés	219.748

```
Taux_faux_positifs_par=sum(abs(gamma_chapo[,15:Dtotal])>seuil_q_n)/(1986*N)
```

```
cardinal_moyen_ensemble_indices_sélectionnés=sum(abs(gamma_chapo)>seuil_q_n)/N #[14+15%*1986]
```

Cardinal_moyen_ensemble_indices_sélectionnés attendu:

$$\mathbb{E} \left(\sum_{j \in \mathcal{M}^*} \mathbb{I}_{|\hat{\gamma}^{(j)}| \geq \text{seuil}} + \sum_{j \in \mathcal{M}^{*c}} \mathbb{I}_{|\hat{\gamma}^{(j)}| \geq \text{seuil}} \right) = 14 + 015 * (1982 + 4) = 161.9.$$

```
Resultats_screening=rbind(round(screen_18_par,3),round(vrais_positifs,3),round(Taux_faux_positifs_par,3),
rownames(Resultats_screening)=c("X1","X2","X3","X4","X5","X6_bern","X7_chisq2","X8=X1*P(2)","X9=N(1,1)*",
"X15=Z3","X16=Z4","X17=Z5","X18=Z6", "taux_vrais_positifs","taux_faux_p
```

```
library(kableExtra)
Resultats_screening %>%
  kable(format = "latex", booktable = TRUE, caption = "N=500, n=2500, $q_n=0.10$, Continuous Output")
```